Ⅰ. 서론

1. 탐구 동기 및 필요성

본 연구는 가족이 차량 손상을 겪은 경험에서 출발하였다. 자동차에 대한 전문 지식이 부족한 운전자는 사진만으로 손상 부위와 정도를 파악하기 어렵고, 수리와 부품 교체 중 어느 쪽이 적절한지 판단하기도 쉽지 않다. 특히 운전 경험이 적은 사람에게는 작은 스크래치조차 어떻게 대처해야 할지 막막할 수 있다.

컴퓨터 비전으로 차량 사진의 손상 부위와 유형을 탐지하고, 그 결과와 수리 관련 정보를 LLM이 설명해 준다면 이러한 정보 격차를 줄일 수 있다. 이에 본 연구에서는 손상 탐지에 그치지 않고 실제 크기 추정과 수리 안내까지 제공하는 AI 기반 웹 서비스를 개발하고자 하였다.

2. 데이터 기반 문제 정의 및 필요성

차량 손상을 분석하려면 손상의 유형과 위치뿐 아니라, 손상이 발생한 차량 부품과 실제 크기 정보도 필요하다. 본 연구에서는 AI Hub의 '차량 파손 이미지 데이터'를 학습 자료로 활용하였다. 손상은 스크래치(Scratch), 덴트(Dent), 파손(Breakage), 이격(Separated)의 네 유형으로 구분하고, YOLO 학습 형식으로 전처리하였다 [1].

이미지 분류는 사진 전체의 종류를 판단하고, 객체 탐지는 물체의 위치를 사각형으로 표시한다. 이와 달리 인스턴스 세그멘테이션은 손상 영역을 픽셀 단위 마스크로 구분한다. 따라서 손상의 모양과 범위를 확인해야 하는 본 연구에는 세그멘테이션이 적합하다 [2].

사진에서 손상 영역이 차지하는 픽셀 크기는 촬영 거리와 각도에 따라 달라지므로 실제 크기를 직접 나타내지 못한다. 이에 본 시스템은 실제 크기를 아는 동전을 기준 물체로 사용한다. 검출된 동전의 실제 지름과 픽셀 지름의 비율을 손상 마스크에 적용하여 면적을 cm^2로 환산하며, 동전이 검출되지 않으면 면적을 px^2로 표시한다. 크기가 알려진 기준 물체로 단일 이미지에서 크기를 추정하는 방법은 기존 연구에서도 다루어졌다 [3], [4].

다만 이 방식은 기준 동전이 실제 동전이고, 손상 부위와 같은 평면에 놓여 있으며, 촬영 각도가 크게 기울지 않았다는 조건을 전제로 한다. 차량 사진 30장을 점검한 결과, 동전이 없는 사진에서도 동전 후보가 출력되는 오탐이 확인되었다. 따라서 환산값은 참고값으로 해석해야 하며, 실제 동전의 검출 여부와 촬영 조건을 함께 확인해야 한다.

분석 결과는 사용자가 이해하고 활용할 수 있는 형태로 제공되어야 한다. 이를 위해 YOLO의 손상 탐지 결과와 EfficientNet-B3의 부품 분류 결과를 LLM에 전달하여, 손상 상태와 고려할 수 있는 수리 방법을 설명하도록 구성하였다. 본 연구가 해결하고자 하는 문제는 손상 위치 · 유형 탐지, 부품 분류, 분석 결과의 쉬운 안내이다. 실제 크기 추정은 검증이 더 필요한 후속 기능으로 남겨 둔다.

3. 탐구 목적

본 연구의 목적은 차량 사진에서 손상 부위와 유형을 탐지하고, 기준 동전으로 면적을 환산하며, 분석 결과를 바탕으로 수리 관련 정보를 안내하는 AI 웹 서비스를 개발하는 것이다. 이미지 분석부터 LLM 기반 보고서 생성까지의 과정을 하나로 연결하여 일반 사용자도 쉽게 활용할 수 있도록 설계하였다.

구체적인 목표는 다음과 같다.

첫째, AI Hub 데이터를 YOLO 학습 형식으로 변환하고 손상 유형 및 세그멘테이션 라벨을 정리한다 [1].

둘째, YOLO 인스턴스 세그멘테이션으로 스크래치, 덴트, 파손, 이격을 탐지한다 [2].

셋째, 동전 탐지 결과를 기준으로 손상 마스크 면적을 cm^2 단위로 환산하고, 동전이 검출되지 않으면 px^2로 제공한다.

넷째, EfficientNet-B3로 손상 부위가 속한 차량 부품을 분류하여 부품별 수리 비용 추정에 활용한다 [5].

다섯째, Flask 서버에서 손상 세그멘테이션·동전 탐지·부품 분류 모델을 실행하고 그 결과를 통합한다.

여섯째, 로컬 비전 모델이 산출한 구조화된 분석 결과를 Groq API의 Qwen 3.8 27B 모델에 전달하여 참고 수리비와 설명 보고서를 생성한다 [6], [7].

초기 기획에는 블랙박스 영상에서 사고 관련 객체를 추적하는 기능도 포함되어 있었다. 그러나 본 연구에서는 사진 기반 손상 분석과 크기 추정, 수리 안내를 우선 구현하고, 영상 분석은 향후 과제로 남겼다.

Ⅱ. 이론적 배경 또는 관련 연구

1. 최신 기술 동향

컴퓨터 비전에서 이미지 분류는 사진 전체의 종류를 판단하고, 객체 탐지는 물체의 위치를 사각형으로 표시한다. 세그멘테이션은 물체의 영역을 픽셀 단위로 구분하므로, 손상의 모양과 범위를 파악해야 하는 자동차 손상 분석에 적합하다 [2].

YOLO는 객체 탐지뿐 아니라 세그멘테이션과 이미지 분류에도 활용된다. 2026년에 공개된 YOLO26은 다양한 비전 작업을 지원하며 실제 기기에서의 효율적인 실행을 고려한 모델이다 [8]. 본 프로젝트에서는 기존 학습 코드와 웹 구현 환경을 고려하여 YOLOv8 계열을 사용하였고, YOLO26은 향후 개선을 위한 참고 기술로 검토하였다.

본 프로젝트는 손상 종류 · 차량 부위 · 손상 영역이 라벨링된 AI Hub의 ‘차량 파손 이미지 데이터’를 YOLO 세그멘테이션 학습에 활용하였다 [1]. 수리 방법과 비용은 손상 유형뿐 아니라 손상된 부품에 따라서도 달라지므로, EfficientNet-B3로 손상 부위의 부품을 분류하였다. EfficientNet은 네트워크의 깊이 · 너비와 입력 이미지 크기를 함께 조정하는 CNN이며, 본 프로젝트에서는 손상 영역과 부품 영역이 겹치는 정도를 기준으로 학습 라벨을 정하였다 [5].

기준 물체를 이용한 크기 추정은 프로젝트 초기 기획과 README 작성 단계부터 고려한 기능이다. 사진에서 손상 영역이 차지하는 비율만으로는 실제 크기를 알 수 없으므로, 동전이나 카드처럼 크기가 알려진 물체를 함께 촬영하여 픽셀과 실제 길이의 비율을 구하는 방식을 구상하였다. 기준 물체를 탐지하기 위해 Roboflow Universe의 ‘loaded kor coin’ 데이터셋을 검토하였다. 이 데이터셋은 10원 · 50원 · 100원 · 500원 동전을 구분하며, 프로젝트에서는 카드를 기준 물체로 활용하는 방안도 함께 고려하였다 [9].

기준 물체의 실제 지름과 이미지에서의 픽셀 지름으로 환산 비율을 구하고, 이를 손상 영역에 적용하면 실제 길이를 추정할 수 있다. 세그멘테이션 마스크를 이용하면 면적도 근사할 수 있다. 다만 기준 물체와 손상 부위가 비슷한 평면에 있어야 하고, 촬영 각도와 원근 왜곡에 따라 오차가 발생하므로 결과는 참고값으로 해석해야 한다 [3], [4].

웹 서비스는 사용자가 업로드한 차량 사진을 Flask 서버로 전달하고, 서버에서 손상 세그멘테이션 · 동전 탐지 · 부품 분류 모델을 실행하도록 구성하였다. 손상 마스크와 동전 탐지 결과는 원본 사진 위에 시각화한다. 동전이 검출되면 그 지름을 기준으로 손상 마스크 면적을 cm^2 로 환산하고, 검출되지 않으면 px^2 로 제공한다. 표본 점검에서는 동전이 없는 차량 사진에도 후보가 출력되는 오탐이 있었으므로, 실제 동전 여부와 같은 평면 조건을 확인해야 한다.

2. 유사 소프트웨어 및 서비스 분석

차량 사진으로 손상을 분석하여 보험 청구나 수리 견적에 활용하는 상용 서비스로 Tractable, Solera Qapter, Mitchell Intelligent Damage Analysis(MIDA)를 조사하였다.

Tractable은 차량 사진에서 손상 영역과 평가 정보를 추출하고, API를 통해 보험사의 사고 처리 시스템과 연동되는 서비스를 제공한다 [10], [11].

Solera Qapter는 이미지 처리와 딥러닝으로 손상의 위치와 유형을 분석하고, 세그멘테이션 결과를 사진 기반 수리 견적 작성에 활용한다 [12].

Mitchell MIDA는 차량 사진에서 손상된 부품을 식별하고, 수리 · 교체 판단에 필요한 정보를 보험 청구 및 견적 플랫폼에 제공한다 [13].

세 서비스와 본 프로젝트의 차이는 표 1과 같다.

표 1. 유사 서비스 및 본 프로젝트 비교

서비스	핵심 기능 및 활용 목적
Tractable	사진으로 손상 상태를 평가하고 신뢰도 정보를 제공하며, 보험 업무 시스템과 연동된다 [10], [11].
Solera Qapter	딥러닝과 세그멘테이션으로 손상 유형 · 위치를 분석하고, 사진 기반 수리 견적에 활용한다 [12].
Mitchell MIDA	손상 부품을 식별하여 수리 · 교체 판단을 지원하며, 보험 청구 및 견적 과정에 연동된다 [13].
본 프로젝트	일반 운전자를 대상으로 YOLO 손상 탐지, 동전 기준 면적 환산, EfficientNet-B3 부품 분류, LLM 보고서를 제공한다.

기존 서비스가 보험사와 정비업체의 손해사정 · 견적 업무에 초점을 둔다면, 본 프로젝트는 일반 운전자가 손상 상태를 이해하도록 돕는 데 목적이 있다. 특히 손상 탐지와 부품 분류 결과를 LLM의 설명으로 연결한다는 점에 초점을 두었다. 다만 상용 서비스와는 데이터 규모와 기술 수준을 직접 비교하기 어렵다. 본 프로젝트는 이들의 기능을 대체하기보다 일반 사용자를 위한 보조 정보를 제공하는 것을 목표로 한다.

3. 생성형 AI의 활용 목적 및 내용

본 연구에서 생성형 AI는 공개 데이터셋 탐색과 아이디어 구체화에 활용하였다. 이를 통해 AI Hub 차량 파손 이미지와 Roboflow 동전 데이터셋 등을 찾았고, YOLO 세그멘테이션 · 동전 탐지 · EfficientNet-B3의 연결 방식과 크기 추정 및 웹 구현 아이디어를 검토하였다. 다만 데이터의 실제 구성과 사용 조건은 원본 제공 사이트에서 확인하였고, 모델 성능은 공식 문서와 학습 결과를 기준으로 판단하였다.

이와 별개로, 웹 서비스에는 Groq API의 Qwen 3.8 27B 모델을 연결하였다. 이 모델은 로컬 비전 분석 결과를 바탕으로 참고 견적을 생성하고, 분석 결과와 견적을 사용자용 보고서로 정리한다 [6], [7].

Ⅲ. 탐구방법 및 에이전트 설계

1. 데이터 수집 및 전처리 과정

차량 손상 탐지 모델의 학습에는 AI Hub의 차량 파손 이미지 데이터를 활용하였다. 데이터는 차량 이미지와 손상 정보를 담은 JSON 주석 파일로 구성되어 있으며, 확장자를 제외한 파일명을 기준으로 이미지와 주석을 연결하였다. 주석의 손상 유형은 Scratch, Dent, Breakage, Separated의 네 클래스로 정리하였다 [1].

JSON에 포함된 세그멘테이션 폴리곤 좌표는 이미지의 너비와 높이를 기준으로 정규화한 뒤 YOLO 세그멘테이션 형식으로 변환하였다 [2]. 이 과정에서 이미지와 주석의 파일명 일치 여부, 지원하지 않는 손상 유형, 유효하지 않은 폴리곤 좌표 등을 검사하였다. 대규모 주석 파일을 효율적으로 처리하기 위

해 주석 확인 과정에는 멀티스레딩을 적용하였다. 최종적으로 학습용 95,000장과 검증용 23,000장을 표본으로 구성하고, YOLO 학습에 필요한 이미지 · 라벨 폴더와 데이터 설정 파일을 생성하였다.

손상 세그멘테이션 모델은 YOLOv8n-seg를 기반으로 하며, Google Colab의 T4 GPU 환경에서 이미지 크기 320px, batch 16, freeze 10, 10 epoch 설정으로 학습하였다 [14], [15]. 기준 물체 탐지에는 Roboflow Universe의 한국 동전 데이터셋을 사용하였다. 이 데이터는 10원, 50원, 100원, 500원 동전의 네 클래스로 구성되며, YOLO 형식으로 변환하여 별도의 동전 탐지 모델 학습에 활용하였다 [9].

차량 부품 분류에는 손상 마스크와 차량 부품 마스크가 함께 포함된 데이터를 사용하였다 [1]. 손상 영역과 부품 영역의 바운딩 박스가 겹치는 비율을 기준으로 손상 이미지에 부품 라벨을 부여하고, 해당 영역을 crop하여 분류 데이터로 구성하였다. 부품 라벨은 앞범퍼, 앞펜더, 전조등, 뒷범퍼, 뒷펜더, 후미등, 옆면, 사이드미러, 스텝, 타이어·휠의 10개 그룹으로 정리하였다. 분류 모델은 ImageNet 사전학습 가중치를 사용하는 EfficientNet-B3로 구성하였다 [5], [16].

2. 에이전트 아키텍처

본 프로젝트는 각 인공지능 모델이 정해진 순서에 따라 결과를 전달하는 AI 파이프라인으로 설계하였다. 핵심 분석은 컴퓨터 비전 모델이 담당하며, 생성형 AI는 분석 결과를 사용자가 이해하기 쉬운 문장으로 바꾸는 보조 역할을 한다.

디자인 씽킹 과정에서는 차량 손상 후 대처 방법을 모르는 초보 운전자를 주요 사용자로 설정하였다. 페르소나 분석을 통해 사용자에게 필요한 정보를 손상 부위, 손상 유형, 손상 규모, 수리 방법 및 예상 비용으로 구체화하였다. 이후 손상 위치를 표시하는 것만으로는 사용자의 문제를 충분히 해결하기 어렵다고 판단하여, 실제 크기 추정, 차량 부품 분류, 결과 설명 기능을 추가하는 방향으로 아이디어를 발전시켰다. 이를 바탕으로 사진 업로드, 분석 결과 확인, 보고서 열람으로 이어지는 웹 화면을 설계하였다 [17]. 다만 실제 사용자를 대상으로 한 사용성 테스트와 피드백 수집은 수행하지 않았다.

알고리즘은 다음 순서로 동작한다. 먼저 Flask 서버가 업로드된 차량 사진을 YOLO 세그멘테이션 모델에 전달하여 손상 영역과 네 가지 손상 유형을 탐지한다. 동전 탐지 모델은 10원 · 50원 · 100원 · 500원 동전을 찾고, 검출된 동전의 알려진 지름을 기준으로 손상 마스크의 픽셀 면적을 실제 면적 단위로 환산한다. 동전이 검출되지 않으면 면적은 px^2로 제공한다. 다만 손상 부위 가까이에 실제 동전을 놓고 촬영한 차량 사진으로 물리적 크기와 비교하는 검증은 수행하지 못했다. 따라서 cm^2 환산은 이론적으로 구현된 기능일 뿐, 실제 크기 측정의 정확도가 검증된 결과로 해석해서는 안 된다. 이어서 손상 경계 주변을 crop하여 EfficientNet-B3에 입력하고 차량 부품을 분류한다. 마지막으로 손상 유형 · 부품 · 면적 등 로컬 비전 모델이 추출한 구조화된 텍스트 결과만 Groq API의 Qwen 3.8 27B 모델에 전달하여, 수리비 참고 범위를 만들고 분석 결과를 보고서로 정리한다. 이때 원본 손상 사진은 외부 생성형 AI로 전송하지 않는다 [6], [7].

Groq API의 Qwen 모델은 손상 여부나 부품을 판정하는 핵심 분석 모델이 아니다. 이미지 기반 손상 탐지와 부품 분류는 각각의 컴퓨터 비전 모델이 담당하며, Qwen에는 원본 사진 없이 이들이 산출한 구조화된 텍스트 결과만 보내 설명과 참고 견적을 생성한다. 수리비 학습 데이터로 별도의 견적 예측 모델을

학습한 것은 아니므로, 생성된 견적은 실제 정비소 견적을 대체하지 않는다. 또한 통합 서비스 표본 테스트는 처리 흐름과 눈에 띄는 오류를 확인하기 위한 정성적 점검이며, 세그멘테이션 마스크와 동전 검출 결과를 각각 정답 라벨과 대조한 독립적인 정량 평가가 아니다. 면적 환산값 역시 실제 동전을 촬영한 물리적 검증이 필요하다.

3. 구현 환경

데이터 전처리와 모델 학습에는 Python 기반 환경을 사용하였다. 이미지와 JSON 주석의 연결 및 YOLO 라벨 변환은 Python 스크립트로 구현하였고, 대규모 세그멘테이션 모델 학습에는 Google Colab의 T4 GPU를 활용하였다 [14], [15]. 손상 탐지에는 YOLOv8n-seg, 기준 물체 탐지에는 YOLOv8n, 차량 부품 분류에는 ImageNet 사전학습 EfficientNet-B3를 사용하였다.

웹 서비스의 서버는 Python Flask로 구현하였다. 사용자 화면은 HTML과 JavaScript를 중심으로 구성하고, 스타일은 Tailwind CSS로 적용하였다. 사진을 Flask API에 업로드하면 서버가 YOLOv8 세그멘테이션 모델, YOLO 동전 탐지 모델, EfficientNet-B3 부품 분류 모델을 차례로 실행한다. 서버에서 생성한 시각화 결과와 부품별 분석은 브라우저로 반환하고, 구조화된 분석 텍스트만 OpenAI 호환 채팅 API를 제공하는 Groq API로 전달한다 [6], [7], [18], [19].

서비스 배포에는 Render를 사용하였다. Flask 애플리케이션은 외부 요청을 받을 수 있도록 호스트와 포트를 설정하였으며, Groq API 키는 배포 환경의 `GROQ_API_KEY` 환경 변수로 관리한다. 전체 시스템은 Python 기반 전처리 · 학습 환경, Flask 서버 기반 모델 추론, 브라우저 사용자 화면 및 Groq API 연동 환경으로 구성된다 [20].

Ⅳ. 연구결과 및 분석

1. 데이터 인사이트 도출

1) 손상 유형 데이터 분포

AI Hub 차량 파손 이미지 데이터의 손상 주석을 유형별로 집계한 결과는 표 2와 같다. 표의 수치는 이미지 장수가 아니라 세그멘테이션 주석(폴리곤)의 개수이다. 한 이미지에 여러 손상 주석이 포함될 수 있으므로, 이 표를 학습 이미지의 클래스별 장수와 같은 의미로 해석해서는 안 된다 [1].

표 2. AI Hub 손상 유형별 주석 분포

손상 유형	주석 수	비율
Scratch	558,284	49.7%
Dent	182,196	16.2%
Breakage	152,531	13.6%
Separated	229,648	20.5%
합계	1,122,659	100.0%

Scratch 주석은 전체의 약 절반인 49.7%로 가장 많았고, Breakage는 13.6%로 가장 적었다. 두 클래스의 주석 수는 약 3.7배 차이가 나, 손상 유형별 데이터 분포가 균등하지 않음을 알 수 있다. 다만 이 수치는 전체 데이터의 주석 분포이므로, 실제 학습에 사용한 표본의 분포와 완전히 같다고 단정할 수는 없다.

학습 과정에서는 별도의 클래스 가중치나 오버샘플링 · 언더샘플링을 적용하지 않았다. 따라서 클래스 불균형이 모델의 손상 유형 학습에 영향을 주었을 가능성이 있다. 그러나 불균형의 영향만을 분리해 측정하는 추가 실험은 수행하지 않았으므로, 낮은 탐지 성능의 원인을 클래스 불균형 하나로 단정할 수는 없다.

2) 데이터 증강과 학습 결과의 관계

손상 세그멘테이션 학습에는 Blur, MedianBlur, ToGray, CLAHE를 각각 낮은 확률로 적용하는 Albumentations 기반 증강 설정을 추가하였다. 이를 통해 약한 흐림, 회색조 변환, 국소 대비 변화 등 촬영 조건의 차이에 대응하도록 하였다. EfficientNet-B3

에는 RandomResizedCrop과 ColorJitter를 적용하여 크롭 범위와 밝기 · 대비 · 채도에 변화를 주었다. 좌우 반전은 좌우 구분이 필요한 부품 라벨에 영향을 줄 수 있어 적용하지 않았다. 동전 탐지 모델에는 별도의 Albumentations 증강을 적용하지 않았다 [21], [22].

증강을 적용했음에도 손상 세그멘테이션의 검증 mAP는 낮게 나타났다. 따라서 증강을 사용했다는 사실만으로 충분한 성능이 확보되는 것은 아니며, 학습 데이터 규모, 주석 품질, 클래스별 표본 수, 모델 학습 설정을 함께 개선해야 한다.

2. 에이전트 성능 검증

1) 손상 세그멘테이션 및 동전 탐지

손상 세그멘테이션에는 YOLOv8n-seg를 사용하였다. 검증 결과 마스크 기준 mAP50은 12.2%, mAP50-95는 3.1%였다 [23]. 두 지표 모두 낮아 손상 영역과 유형을 안정적으로 구분하는 데 한계가 있음을 확인하였다. 실제 이미지에서는 손상으로 보이는 위치를 찾아 마스크를 표시하는 경우도 있었으나, 동일한 영역에 Separated 클래스 예측이 여러 개 겹쳐 출력되는 현상도 관찰되었다. 따라서 일부 이미지에서 손상 위치를 시각적으로 찾아낸 결과와 전체 검증 데이터에서 측정한 정량 지표는 구분하여 해석해야 한다.

기준 동전 탐지 모델은 YOLOv8n으로 학습하였다. 표 3은 100원 동전 객체에 대한 검증 및 테스트 결과를 정리한 것이다 [23].

표 3. 100원 동전 탐지 성능

구분	객체 수	Precision	Recall	AP50	AP50-95
검증	30	58.4%	80.0%	63.5%	56.7%
테스트	46	68.2%	76.1%	70.9%	54.9%

테스트 세트의 AP50은 70.9%로 검증 세트의 63.5%보다 높았으나, AP50-95는 54.9%로 검증 세트의 56.7%보다 낮았다. 두 지표가 서로 다른 방향으로 움직였다는 점에서, IoU 기준에 따라 탐지 성능의 해석이 달라질 수 있음을 알 수 있다. 또한 위 수치는 동전 탐지 데이터셋에서 얻은 평가 결과일 뿐, 차량 사진에서 동전을 기준으로 실제 손상 크기를 정확히 환산할 수 있음을 입증하는 것은 아니다.

2) 차량 부품 분류

EfficientNet-B3는 10개 부품 클래스를 대상으로 평가하였다. 클래스별 10장씩 총 100장의 이미지를 사용하였으며, 전체 정확도는 81.0%, Macro-F1은 81.1%, Weighted-F1은 81.1%였다. 평가 표본이 클래스별로 같은 수로 구성되어 두 F1 지표가 비슷하게 나타났다 [24].

표 4. EfficientNet-B3 부품 분류 성능

부품 클래스	Precision	Recall	F1
앞범퍼	60.0%	90.0%	72.0%
앞펜더	69.2%	90.0%	78.3%
전조등	100.0%	70.0%	82.4%
뒷범퍼	100.0%	80.0%	88.9%
뒷펜더	100.0%	50.0%	66.7%
후미등	83.3%	100.0%	90.9%
옆면	64.3%	90.0%	75.0%
사이드미러	100.0%	90.0%	94.7%
스텝	88.9%	80.0%	84.2%
타이어 · 휠	87.5%	70.0%	77.8%

사이드미러의 F1이 94.7%로 가장 높았고, 후미등이 90.9%, 뒷범퍼가 88.9%로 뒤를 이었다. 반면 뒷펜더는 66.7%로 가장 낮았으며, 앞범퍼는 72.0%였다. 뒷펜더는 Precision이 100%이지만 Recall이 50%로, 뒷펜더라고 예측한 경우는 모두 맞았으나 실제 뒷펜더 이미지의 절반을 놓쳤다는 뜻이다. 이처럼 전체 정확도만으로는 클래스별 강점과 약점을 알기 어려우므로, 부품별 지표를 함께 확인해야 한다.

3) 통합 웹 서비스 테스트

학습 및 모델별 평가에 사용한 이미지와는 별도로, 기존 데이터셋에서 추출한 차량 이미지 약 30장으로 웹 서비스의 전체 처리 흐름을 점검하였다. 10개 부품 클래스에서 각각 3장

씩 선정하였으며, 네 가지 손상 유형도 테스트에 포함하였다. 이 테스트는 실제 사용자가 촬영한 차량 사진을 대상으로 한 현장 검증은 아니다.

30장 모두에서 서비스가 중단되는 치명적인 실행 오류는 발생하지 않았다. 다만 6장에서 경미한 분석 오류가 관찰되었다. 오류 유형별 발생 건수는 손상 유형 오분류 5건, 손상 영역 판단 오류 3건, 부품 분류 오류 1건이었다. 한 이미지에서 두 가지 이상의 오류가 함께 나타날 수 있으므로, 오류 유형별 건수의 합은 오류가 발생한 이미지 수와 일치하지 않는다.

이 결과는 테스트 표본에서 관찰된 오류를 요약한 것이다. 따라서 24장을 오류 없이 처리했다는 사실을 곧바로 시스템 정확도 80%로 해석해서는 안 된다. 원본 이미지와 정답 주석을 함께 살펴보는 정성적 점검은 수행하였으나, 세그멘테이션 마스크와 동전 탐지 결과 각각에 대해 정답 라벨과 비교한 별도의 지표는 산출하지 않았다. 따라서 통합 테스트는 서비스 연결과 처리 가능성을 확인한 초기 점검으로 보는 것이 적절하다.

Qwen 3.8 27B가 생성한 보고서에는 손상 유형, 손상 위치, 손상 면적 또는 크기 정보, 차량 부품명, 손상 상태에 대한 설명, 수리 안내와 예상 수리비가 포함되었다. 수리비는 원화 기준으로 부품 교체비와 공임을 구분하고, 각 항목을 최소 · 최대 금액 범위로 제시하도록 구성하였다. 테스트 과정에서 보고서의 설명은 사용자가 결과를 이해하는 데 적절한 수준으로 판단되었다. 다만 차량 모델과 연식은 입력하지 않았고 생성된 수리비를 실제 정비소 견적과 대조하지도 않았으므로, 해당 금액은 참고용 추정치이다.

4) 처리 시간

이미지 1장을 처리하는 데 관찰된 전체 소요 시간은 약 10초였다. 단계별로는 클라이언트 측 모델 로딩이 약 6초, 분석 및 결과 추정이 약 1초, Qwen 보고서 생성이 약 3초였다.

표 5. 이미지 1장 처리 시간

처리 단계	소요 시간
클라이언트 측 모델 로딩	약 6초
분석 및 결과 추정	약 1초
Qwen 보고서 생성	약 3초
전체	약 10초

이 시간은 실험 당시 서비스에서 관찰한 대략적인 값이며, 기기 성능과 네트워크 상태 등에 따라 달라질 수 있다. 특히 모델 로딩과 이미지 분석은 서로 다른 단계이므로, 이후 성능을 비교할 때는 최초 모델 로딩을 포함한 전체 응답 시간과 모델이 준비된 뒤의 순수 추론 시간을 구분하여 측정해야 한다.

3. 사례 적용: 실제 생활 시나리오

다음은 개발한 서비스의 활용 절차를 설명하기 위한 예시 시나리오이다. 특정 테스트 이미지에서 실제로 확인된 수리 결과나 견적을 재현한 것이 아니라, 구현된 기능을 일상 상황에 적용하여 설명한 것이다.

운전자가 주차 후 차량 측면에 손상이 생긴 것을 발견했다고 가정한다. 운전자는 손상 부위가 잘 보이도록 사진을 촬영하여 웹 서비스에 업로드한다. 서비스는 YOLOv8n-seg로 손상 후보 영역과 손상 유형을 찾고, EfficientNet-B3로 해당 영역이 속한 부품을 분류한다. 사진에서 동전이 검출되면 기준 동전의 지름을 이용한 면적 환산값을 제공하도록 설계되어 있으며, 검출되지 않으면 픽셀 단위 면적을 표시한다. 다만 실제 동전을 손상 부위와 같은 평면에 놓고 촬영한 사진으로 물리적 크기를 검증하지는 않았다. 따라서 환산 면적은 실제 수리 범위를 확정하는 수치가 아니라 참고 정보로 보아야 한다.

이후 Qwen 3.8 27B는 비전 모델이 산출한 구조화된 결과를 바탕으로 손상 유형과 위치, 해당 부품, 손상 상태, 고려할 수 있는 수리 방법을 문장으로 정리한다. 수리비는 부품

교체비와 공임을 구분한 최소 · 최대 범위로 제시한다. 운전자는 이 정보를 통해 정비소를 방문하기 전에 손상에 관한 기초 정보를 파악하고, 상담 시 물어볼 항목을 정리할 수 있다.

그러나 이 서비스의 결과만으로 수리 여부나 최종 비용을 결정해서는 안 된다. 사진만으로는 확인하기 어려운 내부 손상, 차종 · 연식 · 부품 가격의 차이, 정비소별 공임 등이 반영되지 않았기 때문이다. 따라서 이 서비스는 정비사의 현장 점검을 대체하는 자동 견적 시스템이 아니라, 사용자가 손상 상태를 이해하고 정비 상담을 준비하도록 돕는 사전 정보 제공 도구로 활용하는 것이 적절하다.

Ⅴ. 결론 및 성찰, 탐구 결론

1. 탐구 결론

본 연구에서는 차량 사진에서 손상 부위와 유형을 탐지하고, 차량 부품을 분류한 뒤 분석 결과를 바탕으로 수리 정보를 제공하는 AI 웹 서비스를 개발하였다. YOLOv8n-seg, 동전 탐지 YOLOv8n, EfficientNet-B3를 각각의 역할에 맞게 구성하고, 분석 결과를 Qwen 3.8 27B가 자연어 보고서로 정리하도록 연결하였다.

모델별 평가에서 EfficientNet-B3는 100장 평가 이미지에서 81.0%의 정확도를 기록하였고, 동전 탐지 모델도 별도의 검증 · 테스트 데이터에서 탐지 성능을 확인하였다. 반면 손상 세그멘테이션의 mAP50은 12.2%, mAP50-95는 3.1%로 낮게 나타났다. 통합 서비스 테스트 약 30건에서는 프로그램이 중단되는 오류는 없었으나, 6건에서 손상 종류나 영역, 부품 분류와 관련한 사소한 오류가 관찰되었다. 이를 통해 여러 AI 모델을 하나의 웹 서비스로 연결하는 것은 가능했지만, 손상 탐지의 정확도와 실제 환경에서의 신뢰성을 더 높여야 한다는 점을 확인하였다.

2. AI 윤리 및 한계점

AI가 제공하는 분석 결과와 수리비를 사용자가 확정적인 진단이나 견적으로 받아들이지 않도록 해야 한다. 특히 Qwen 3.8 27B가 제시하는 수리비는 손상 유형, 부품, 크기 등의 정보를 바탕으로 생성한 참고용 추정치이다. 차량 모델과 연식, 부품 가격 및 정비소별 공임을 반영하지 않았으며, 실제 정비소 견적과 비교하는 검증도 아직 수행하지 않았다. 따라서 서비스에는 AI 추정 결과라는 점을 분명히 표시하고, 최종 수리 판단은 정비 전문가의 확인을 거치도록 안내할 필요가 있다.

데이터의 편향과 개인정보 보호도 고려해야 한다. AI Hub 데이터의 손상 유형별 주석 수에는 차이가 있으며, 본 연구에서는 별도의 클래스 가중치나 오버샘플링을 적용하지 않았다. 차량 사진에는 번호판이나 주변 사람의 모습이 포함될 수 있으므로 실제 서비스에서는 이미지 저장을 최소화하고, 접근 권한과 전송 보안을 관리하며, 필요하면 번호판과 얼굴을 가리는 기능을 추가해야 한다. 또한 데이터셋과 사전학습 모델을 사용할 때에는 제공자의 라이선스와 이용 조건을 확인해야 한다 [1], [9], [16].

본 연구의 성능 검증에도 한계가 있다. 통합 테스트는 기존 데이터셋 이미지 약 30장을 이용한 것이며, 실제 사용자가 촬영한 차량 사진으로 현장 검증을 진행하지 못했다. 동전 기준 크기 추정은 구현 원리를 구성하고 픽셀 단위 비교를 수행했으나, 손상 부위 가까이에 동전을 놓고 촬영한 실제 차량 사진으로 물리적 크기의 정확도를 검증하지는 않았다. 또한 세그멘테이션과 동전 탐지 결과를 통합 테스트 이미지의 정답 마스크와 각각 대조한 별도 정량 평가는 수행하지 않았다. 따라서 현재 결과를 실제 차량 환경 전반에 적용할 수 있는 성능으로 확대 해석하기는 어렵다.

3. 향후 발전 계획

가장 먼저 손상 세그멘테이션 모델의 성능을 개선하고자 한다. 초기에는 AI Hub 전체 데이터 약 41만 장을 이용해 약 30 epoch 학습하는 것을 계획했으나, 당시 사용 가능한 연산 환경에서는 학습 시간이 지나치게 길어 일부 데이터만 사용하였다. 향후 로컬 GPU나 클라우드 GPU를 활용해 더 많은 데이터를 학습하고, epoch 수를 늘린 결과와 현재 모델을 비교할 계획이다. 클래스별 데이터 분포를 고려한 샘플링이나 가중치 적용도 추가로 실험할 수 있다.

다음으로 실제 차량 사진을 이용한 크기 추정 검증이 필요하다. 손상 부위와 기준 동전을 같은 평면에 배치해 촬영하고, 수동으로 측정한 픽셀 크기 및 실제 길이와 모델의 추정값을 비교하여 오차를 확인하고자 한다. 촬영 각도와 거리, 조명 조건을 달리한 사진도 수집해 기준 물체를 이용한 환산 방식의 적용 범위를 확인할 계획이다.

마지막으로 Qwen의 수리비 추정 결과를 실제 정비소 견적이나 신뢰할 수 있는 수리비 자료와 비교할 예정이다. 이후 차량 모델과 연식, 부품 정보 등을 입력에 포함하는 방법을 검토하고, 실제 사용자를 대상으로 사용성 평가를 진행해 설명의 이해도와 서비스의 편의성을 개선하고자 한다.

Ⅵ. 느낀점

이번 탐구를 진행하면서 인공지능 서비스를 만드는 과정은 모델을 학습시키는 것만으로 끝나지 않는다는 점을 알게 되었다. 데이터를 수집하고 주석을 정리하는 일부터 모델의 학습 환경을 구성하고, 서로 다른 모델의 결과를 하나의 서비스로 연결하는 과정까지 많은 작업이 필요했다. 특히 손상 영역을 탐지하는 모델은 실제 이미지에서 어느 정도 손상 부위를 표시하더라도 정량 평가 지표는 낮게 나타날 수 있다는 점이 인상적이었다. 눈으로 보기에 괜찮은 결과와 객관적인 성능 평가는 서로 구분해야 한다는 것을 배웠다.

또한 여러 모델을 연결할 때 앞 단계의 오류가 뒤 단계에도 영향을 준다는 점을 확인하였다. 손상 유형이나 부품을 잘못 판단하면 이후 생성되는 수리 안내와 비용 추정도 부정확해질 수 있다. Qwen 3.8 27B는 분석 결과를 이해하기 쉬운 문장으로 바꾸는 데 유용했지만, 자연스러운 설명이 항상 정확한 정보를 의미하지는 않았다. 생성형 AI의 역할을 결과 설명으로 한정하고, 실제 분석과 판단은 별도의 모델과 검증 과정에 맡기는 것이 중요하다고 느꼈다.

연구를 진행하면서 연산 자원의 한계도 크게 경험하였다. 전체 데이터 약 41만 장을 충분히 학습시키려던 계획은 학습 시간 문제로 실행하지 못했고, 그 결과 모델 성능을 더 개선할 기회를 놓쳤다. 이를 통해 좋은 아이디어와 모델 구조뿐 아니라 이를 실험할 수 있는 컴퓨팅 환경도 연구 결과에 큰 영향을 준다는 점을 알게 되었다.

무엇보다 이번 연구를 통해 결과를 과장하지 않고 한계를 정확하게 기록하는 태도가 중요하다는 것을 배웠다. 실제 차량 사진을 직접 촬영하지 못했고, 동전 기준 크기 추정과 수리비 역시 실제 환경에서 충분히 검증하지 못했다. 이러한 부분을 완성된 기능처럼 표현하기보다 현재 확인한 결과와 앞으로 검증해야 할 내용을 구분하는 것이 연구의 신뢰성을 높인다고 생각한다. 앞으로는 모델을 구현하는 데 그치지 않고, 더 많은 데이터와 실제 환경의 평가를 통해 문제를 확인하고 개선하는 연구를 이어가고 싶다.

Ⅶ. 참고문헌

[1] AI Hub, “차량 파손 이미지 데이터.” Accessed: Nov.

01, 2026. [Online]. Available: https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=581

[2] Ultralytics, “Instance Segmentation with Ultralytics YOLO.” Accessed: Nov. 01, 2026. [Online]. Available: https://docs.ultralytics.com/tasks/segment

[3] N. Yanase, K. Murasaki, Y. Shimada, and Y. Taniguchi, “A Study of Object Size Estimation from a Single Image,” in Proceedings of the ITE Annual Convention 2016, 2016, pp. 21C-4. doi: 10.11485/iteac.2016.0_21C-4.

[4] N. Pears, P. Wright, and C. Bailey, “Practical Single View Metrology for Cuboids,” in Proceedings of the Second International Conference on Computer Graphics Theory and Applications (GRAPP), Barcelona, Spain: INSTICC, 2007, pp. 85-90. [Online]. Available: https://www.scitepress.org/papers/2007/20424/20424.pdf

[5] M. Tan and Q. V. Le, “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks,” in Proceedings of the 36th International Conference on Machine Learning, in Proceedings of Machine Learning Research, vol. 97. 2019, pp. 6105-6114. [Online]. Available: https://proceedings.mlr.press/v97/tan19a.html

[6] Groq, “API Reference: Chat Completions.” Accessed: Nov. 03, 2026. [Online]. Available: https://console.groq.com/docs/api-reference

[7] Groq, “Supported Models.” Accessed: Nov. 03, 2026. [Online]. Available: https://console.groq.com/docs/models

[8] G. Jocher, J. Qiu, M. Liu, S. Lyu, F. C. Akyon, and M. E. Kalfaoglu, “Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models.” [Online]. Available: https://arxiv.org/abs/2606.03748

[9] visitor, “loaded kor coin Dataset.” Accessed: Nov. 01, 2026. [Online]. Available: https://universe.roboflow.com/visitor/loaded-kor-coin/dataset/2

[10] Tractable, “AI-Powered Damage Assessment for Vehicles and Properties.” Accessed: Nov. 01, 2026. [Online]. Available: https://tractable.ai/

[11] Tractable, “Admiral Seguros: AI-Powered Vehicle Damage Assessment.” Accessed: Nov. 01, 2026. [Online]. Available: https://tractable.ai/case-studies/admiral-seguros/

[12] Solera Qapter, “Qapter: AI-Powered Vehicle Claims and Damage Estimating.” Accessed: Nov. 01, 2026. [Online]. Available: https://www.qapter.com/technology/

[13] Mitchell International, “Artificial Intelligence: Mitchell Intelligent Damage Analysis.” Accessed: Nov. 01, 2026. [Online]. Available: https://www.mitchell.com/about/innovations/artificial-intelligence

[14] Google, “Colab: Getting Started.” Accessed: Nov. 03, 2026. [Online]. Available: https://colab.research.google.com/notebooks/intro.ipynb?hl=ko-KR

[15] Ultralytics, “Model Training with Ultralytics YOLO.” Accessed: Nov. 03, 2026. [Online]. Available: https://docs.ultralytics.com/modes/train

[16] PyTorch, “efficientnet_b3 – Torchvision Documentation.” Accessed: Nov. 03, 2026. [Online]. Available: https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.efficientnet_b3.html

[17] Stanford d.school, “Design Thinking Bootleg.” Accessed: Nov. 03, 2026. [Online]. Available: https://dschool.stanford.edu/tools/design-thinking-bootleg

[18] Pallets Projects, “Welcome to Flask.” Accessed: Nov. 03, 2026. [Online]. Available: https://flask.palletsprojects.com/en/stable/

[19] Tailwind Labs, “Tailwind CSS Documentation.” Accessed: Nov. 03, 2026. [Online]. Available: https://tailwindcss.com/docs

[20] Render, “Deploy a Flask App on Render.” Accessed: Nov. 03, 2026. [Online]. Available: https://render.com/docs/deploy-flask

[21] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, “Albumentations: Fast and Flexible Image Augmentations,” Information, vol. 11, no. 2, p. 125, 2020, doi: 10.3390/info11020125.

[22] PyTorch, “Torchvision Transforms Documentation.” Accessed: Nov. 03, 2026. [Online]. Available: https://docs.pytorch.org/vision/stable/transforms.html

[23] Ultralytics, “YOLO Performance Metrics.” Accessed: Nov. 03, 2026. [Online]. Available: https://docs.ultralytics.com/guides/yolo-performance-metrics

[24] scikit-learn developers, “Metrics and Scoring: Quantifying the Quality of Predictions.” Accessed: Nov. 03, 2026. [Online]. Available: https://scikit-learn.org/stable/modules/model_evaluation.html